赵晗瑜

性　别：女　　联系电话：19933153268

联系邮箱：zhy19933153268@163.com

教育经历

2020-09 ~ 2024-07　　**华东师范大学(985)**　　**软件工程（本科）**

GPA：3.87/4.0（前5%）｜ **资格证书：**CET-6，雅思6.0　｜ 个人网站：*https://hot-zhy.github.io/freya*

荣誉奖项：华东师范大学优秀学业奖学金特等奖 | 上海市优秀毕业生 | 2024 AIGC高校计算机设计大赛全国二等奖 | 2024全球数学推理与解题比赛二等奖 | 2024中国研究生人工智能创新大赛（华为杯）全国三等奖

2024-09 ~ 至今　　**华东师范大学(985)**　　**软件工程 (27年毕业)（硕士）**

研究方向：智能教育（AI4Edu）**一区top期刊**论文已accept (**I**nformation **P**rocessing & **M**anagement)，一篇ccf B在投

实习经历

2025-12 ~ 2026-03　　**英伟达(Nvidia)**　　**软件开发**

技术栈：*Python，Django，JavaScript/jQuery，Plotly，SQLite，REST API，PyInstaller，GitLab CI，Kubernetes，LLM/Agent*

部门项目：NVPunish Web UI（GPU 压力测试平台可视化与批量故障分析）

- **可视化分析平台建设**：设计多机多Job执行流Gantt图与Failure Analytics看板，基于Ploty实现交互式状态展示，秒级刷新与RCA入口联动；支持Running/Pending/Completed状态追踪，多DUT报告聚合/汇总导出及GPU遥测指标展示。
- **Batch RCA Pipeline**：构建面向1000+高频失败模式的自动化根因分析链路，通过上下文预处理、频次过滤、版本归因生成pattern-level分析上下文，并采用**滑动窗口**并发调度的**AI SubAgents**追踪failure sequence、定位关联源码函数并输出结构化的**root case report**、支持幂等恢复与断点续跑，替代人工逐模式排查。
- **后端开发与工程化**：使用Django搭建Web后端对接NvPunish REST API，开发10+API端点，覆盖测试管理、报告、配置与RCA查询。

2025-09 ~ 2025-12　　**喜马拉雅**　　**Agent后端开发**

技术栈：*Python，Dify，AI Agent，Mem0，RabbitMQ，LLM，Milvus，MCP*

部门项目：喜马拉雅主 App｜ “智慧大师”智能陪伴与建议系统: 面向不同年龄段、处于困扰/压力场景的用户，提供个性化分析、指导建议与可执行行动方案；负责后端架构与智能工作流建设，提升用户画像沉淀、检索推荐效率与高并发稳定性。

- **用户画像与特征抽取（LLM + 长期记忆）**： 基于 Dify 编排对话解析 Workflow，使用 LLM 对用户多轮对话与行为日志进行结构化抽取（偏好标签、主题兴趣、关键事件、情绪波动等），并将结果写入 **Mem0** 作为“长期记忆”向量/结构化混合存储，形成可检索的时间序列记忆，为 Agent 在后续对话中实时读取和引用用户历史提供支持。
- **多源信息融合与 Agent 调度**： 利用 MCP 将账号信息、行为特征、Mem0 长期记忆与外部工具封装为可调用资源，构建“Main Agent + Sub Agent（情绪分析、行动计划、知识检索等）”协作模式。通过 RabbitMQ 将特征抽取、向量化写入、Mem0 同步等高延迟步骤**异步化**，实现削峰填谷，将高峰期 Agent 工具调用超时率降低约 60%。
- **向量召回与兴趣/情绪聚类：**将用户画像与 Mem0 关键记忆统一语义向量化并存入 Milvus，构建基于相似度的 ANN 向量检索，结合聚类与情绪标签完成兴趣分群与主题归因，实现同时考虑“当前情绪、历史偏好、长期目标”的多维召回，使相关内容点击率提升约 8%–12%。

2025-04 ~ 2025-08　　**上海智能教育研究院**　　**服务端开发**

技术栈：*Python、Java/Spring Boot、MySQL、Redis、Docker、Kubernetes、Caffine、OCR、LLM、Dify、Agent*

部门项目：智能教育平台｜ “小花狮”智能作文辅导系统（10,000+ 用户量级）

- **高并发Agentic AI架构：**设计Agentic Workflow，将批改作文功能拆分为任务理解、工具调用、结果评估与反馈回传等阶段，并通过RabbitMQ实现异步编排、削峰填谷与任务解耦，结合**Caffeine+Redis多级缓存**体系，配合Lua脚本实现任务流控，使核心接口响应提升42%，数据库查询压力降低52%。
- **AI批改链路工程化：** 负责作文批改模块落地，基于LangChain构建Multi-Agent系统，结合SSE提供流式返回体验，引入RAG增强知识注入能力；建立bad case回流与提示词/规则迭代机制，持续优化批改结果的稳定性与准确性。
- **高频接口性能治理：**负责教师/学生端高频接口（班级管理、作业列表）性能治理，结合Redis热点数据缓存、慢SQL排查、索引优化与SQL改写，支撑峰值QPS 2000+，接口P99降至100ms以内，保障开学季稳定上线。

2024-11 ~ 2025-04　　**上海人工智能创新中心**　　**后端开发**

技术栈：*Go, Redis, Redis Stream, SSE, Consumer Group，微服务架构*

部门项目：Go 微服务｜科研助手（思维导图生成）： 面向科研人员，提供思维导图自动生成服务，帮助用户将输入的科研内容或资料转化为结构化的知识网络。负责后端微服务架构与流式数据处理，提升用户数据管理效率与系统稳定性。

- **导图生成**：针对论文篇幅长、超出单次 LLM 上下文限制的问题，先按章节/段落对文本切分并并行调用 LLM 完成局部结构化，再通过二次聚合与冲突合并将各段结果归并为统一的节点-边层级 JSON，将复杂科研文本稳定转换为可直接渲染的思维导图数据。
- **流式推送与一致性保障（Redis Stream + SSE）**：以 **Redis Stream** 承载导图生成的中间结果与进度更新，前端通过 SSE 持续订阅并增量渲染导图节点，相比一次性返回显著缩短首屏可见时间；按任务/会话维度记录消费位点实现断线续推，并结合 Consumer Group 与基于 **Redission**内置的分布式锁（SET NX EX + Lua 脚本）治理多实例并发消费，避免重复推送、消息丢失与结果乱序。

项目经历

2024-09 ~ 至今 **Java课堂AI小助手和Java AI面试系统（一区论文accept）** **前后端开发+算法开发**

项目：AI 智能课堂助手|智能化学习与个性化辅导系统： 面向学生提供知识问答、编程训练、自适应推荐与模拟面试等AI学习服务，学生满意度84%。

技术栈： *Spring Boot、Flask、Redis、RAG、LLM、Embedding / 向量检索、SSE、知识追踪、推荐算法*

- **后端架构与AI服务解耦**：负责系统后端架构与核心功能落地，采用 **Spring Boot + Flask** 解耦业务服务与 AI 推理链路；Spring Boot 承载业务接口、题库管理、学习记录与流程编排，Flask 承载向量化、检索增强与模型推理服务，统一支撑知识问答、编程辅导、自适应推荐与模拟面试等场景。
- **RAG知识问答链路**：构建面向 Java 知识点的 **RAG 全链路**，完成文档切分、文本向量化、相似度检索与增强生成闭环，同时设计基于**Query Rewrite**的增强架构，通过LLM将短查询、模糊语义转化为**可检索语句**，并结合短Token物理命中判定，将语义检索准确率提升30%以上，同时实现基于文件内容特征SHA-256哈希的去重检测逻辑，在解析前拦截重复文档上传，有效避免AI接口的冗余调用与存储资源浪费。
- **异步处理与流式交互：** 基于 **RabbitMQ** 构建异步处理链路，通过生产者-消费者模型将向**量化、代码评测与学习反馈**等耗时任务从同步请求中拆出，结合任务状态持久化与 **SSE/前端轮询** 回传处理结果，降低接口阻塞与超时风险，提升稳定性与吞吐能力。
- **编程辅导与个性化推荐：** 搭建"代码提交，自动评测，LLM 反馈，结果回传"，支持从正确性、风格与效率等维度生成个性化建议；基于**知识追踪**与作答历史实现**动态题目推荐**，并在模拟面试中支持**自适应选题**，形成闭环学习路径。
- **表情与语音分析**：基于前端摄像头与麦克风采集实时视频/音频流，通过调用第三**方表情识别与语音情感分析**服务（HTTP/REST 接口 + WebSocket 流式识别），获取**表情类别、情绪得分、语速与语调**等特征；在后端以 Spring Boot 统一封装情绪分析 API，将结果写入**学生学习画像**（Redis/数据库）并注入 LLM 提示词，用于动态调整反馈语气、鼓励强度与题目难度。

2023-10 ~ 2024-01 **AAAI 2024 全球数学解题与推理竞赛** **全球第二名**

项目：大语言模型数学问题求解与推理能力提升： 解决大语言模型在数学问题求解与推理方面的能力不足，基于 ChatGLM 提升其在数学题目中的表现。通过多种技术手段（如 Prompt 工程、LoRA 微调、PAL 编程辅助语言以及多模型投票），显著提高了模型的解题准确性与推理能力。

技术栈：ChatGLM, LoRA, K-Means, PAL, 多模型集成

- **题型感知 Prompt 设计：** 围绕数学题求解场景设计并优化 Prompt，结合 Chain-of-Thought 增强模型的分步推理能力；基于 K-Means 对题目进行聚类，构建题型感知的 Few-shot 示例选择策略，提升不同类型数学题目的上下文匹配度与推理质量。
- **LoRA 专项微调**：整理高质量数学题数据集，围绕不同题型构建训练样本，并基于 LoRA 对 ChatGLM 进行**轻量化微调**，训练多个面向不同数学问题分布的子模型，提升模型在专项题型上的求解表现与适应能力。
- **PAL 程序辅助求解**：针对计算型和复杂推理型数学问题，引入 **Program-Aided Language（PAL）** 方法，使用大语言模型生成可执行代码并通过程序运行获得中间结果与最终答案，降低纯自然语言推理中的计算误差，提升复杂题目的求解精度。
- **集成推理与结果融合**：针对多个微调子模型设计**多模型投票与结果融合机制**，对候选答案进行一致性比较与最优选择，进一步提升最终推理结果的稳定性与准确性。

专业技能

- **AI应用开发**：熟悉 LLM 应用开发与 Agentic Workflow 设计、 RAG、向量检索/Embedding、Prompt Engineering、Function Calling、MCP、Memory Management、Skills、Multi-Agent、LangChain、LangGraph、Supervised Fine-Tuning (SFT)、Reinforcement Learning (RL)
- **后端开发**：熟悉 Java / Python 后端开发，具备 Spring Boot、Flask、Django 项目实践经验。
- **数据库与检索**：熟悉 MySQL、SQLite、Redis 等常用存储组件，理解索引、事务、MVCC、慢 SQL 排查、索引优化与 SQL 改写；具备缓存设计、分布式锁、Redis Stream / Consumer Group、向量检索等实践经验。
- **前端与可视化**：具备 React/Vue3+ TypeScript、JavaScript / jQuery等开发经验，能够完成 AI 应用前端交互、数据看板与可视化分析页面开发。
- **计算机基础**：熟悉 HTTP / TCP-IP 等网络基础，熟练使用 Git、Linux、Shell 等开发工具，具备系统排障与工程协作能力。